

# Una pequeña charla sobre EBM's y SBMs

## Un vistazo a los modelos generativos - Parte 2

03.03.2026

Ángel Aarón Flores Alberca



# Índice


|                                                                |    |
|----------------------------------------------------------------|----|
| 1. Modelos basados en energía .....                            | 3  |
| 1.1. ¿Qué son? .....                                           | 4  |
| 1.2. Definición matemática .....                               | 6  |
| 1.3. Optimización de EBMs .....                                | 7  |
| 2. Score Matching .....                                        | 10 |
| 2.1. ¿Qué es el score? .....                                   | 11 |
| 2.2. ¿Por qué trabajar con el score? .....                     | 12 |
| 2.3. Entrenamiento de EBMs mediante Score Matching .....       | 15 |
| 3. Dinámica de Langevin .....                                  | 27 |
| 3.1. ¿Cómo surge? .....                                        | 28 |
| 3.2. Dinámica de Langevin en tiempos continuo y discreto ..... | 31 |
| 3.3. Limitaciones del muestreo de Langevin .....               | 33 |
| 4. Referencias .....                                           | 34 |
| 4.1. Referencias .....                                         | 35 |

# **1. Modelos basados en energía**

## ¿Qué son?

Los **modelos basados en energía (Energy Based Models - EBMs)** son una subclase de los modelos generativos que toman inspiración de conceptos de física estadística en la que se define una función de densidad de probabilidad para modelar un escalar de energía a cada configuración posible de un sistema con muchas partículas (fluidos):

- Las moléculas de un gas en reposo forman configuraciones de baja energía. (estables y probables)
- Las moléculas de un líquido agitado forman configuraciones de alta energía. (inestables e improbables)



## ¿Qué son? (ii)

Análogamente podemos trasladar esta intuición al reemplazar particular por datos como imágenes, textos o valores de una distribución probabilística y se define un escalar de energía a cada configuración posible:

- Entradas que se asemejen más a datos reales reciben una energía baja.
- Entradas sin sentido o ruido puro reciben una energía alta.

A diferencia de modelos variacionales, los EBM's no necesitan definir explícitamente como definir datos ni normalizar su distribución, solo necesitan verificar la configuración de los valores de entrada.

**Ojo:** Los modelos basados en energía tienen un rango de casos de uso más extenso que la de inteligencia artificial generativa que varían entre:


- Reconstrucción de imágenes.
- Aprendizaje por refuerzo.
- Clasificación y tareas de predicción estructurada.
- Detección de anomalías.

## Definición matemática

Sea  $\mathbf{x} \in \mathbb{R}^D$  un vector de datos, los EMBs definen una función de densidad de probabilidad mediante una función de energía  $E_\phi(\mathbf{x})$  parametrizado por  $\phi$  igual al siguiente expresión:

$$p_\phi(\mathbf{x}) := \frac{\exp(-E_\phi(\mathbf{x}))}{Z_\phi} \quad Z_\phi := \int_{\mathbb{R}^D} \exp(-E_\phi(\mathbf{x})) d\mathbf{x}$$

Donde  $Z_\phi$  es definido como la *función de partición* que asegura *normalización* de nuestra función de probabilidad.



# Optimización de EBM

Retomando lo visto en la clase previa, nuestro objetivo en modelos generativos será la de disminuir la **divergencia** entre las distribuciones de datos y nuestro modelo que se traduce directamente en disminuir la **entropía cruzada** entre dichas distribuciones.

Así obtenemos lo siguiente:

$$\begin{aligned}\mathcal{L}_{\text{MLE}}(\phi) &= \min \mathcal{H}(p_{\text{data}}, p_{\phi}) = \max \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\log p_{\phi}(\mathbf{x})] \\ &= \max \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \log \frac{\exp(-E_{\phi}(\mathbf{x}))}{Z_{\phi}} \right] \\ &= \max \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\log \exp(-E_{\phi}(\mathbf{x}))] - \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\log Z_{\phi}] \\ &= \min \underbrace{\mathbb{E}_{p_{\text{data}}(\mathbf{x})} [E_{\phi}(\mathbf{x})]}_{\text{Reduce la energía de los datos}} + \underbrace{\log Z_{\phi}}_{\text{Regularización global}}\end{aligned}$$

## Optimización de EBMs (ii)

Sin embargo, para altas dimensiones de  $D$  computar  $\log Z_\phi$  y su gradiente es **intratable** debido a que no podemos evaluar su valor, ya que corresponde a un espacio de integración muy grande como  $\mathbb{R}^D$ , así mismo al querer obtener su gradiente:

$$\begin{aligned}\nabla_\phi \log Z_\phi &= \nabla_\phi \log \int_{\mathbb{R}^D} \exp(-E_\phi(\mathbf{x})) \, d\mathbf{x} \\&= \frac{1}{\int_{\mathbb{R}^D} \exp(-E_\phi(\mathbf{x})) \, d\mathbf{x}} \int_{\mathbb{R}^D} \nabla_\phi \exp(-E_\phi(\mathbf{x})) \, d\mathbf{x} \\&= \int_{\mathbb{R}^D} \underbrace{\frac{\exp(-E_\phi(\mathbf{x}))}{\int_{\mathbb{R}^D} \exp(-E_\phi(\mathbf{x})) \, d\mathbf{x}}}_{p_\phi(\mathbf{x})} - \nabla_\phi E_\phi(\mathbf{x}) \, d\mathbf{x} \\&= - \int_{\mathbb{R}^D} p_\phi(\mathbf{x}) \nabla_\phi E_\phi(\mathbf{x}) \, d\mathbf{x} = -\mathbb{E}_{p_\phi(\mathbf{x})} [\nabla_\phi E_\phi(\mathbf{x})]\end{aligned}$$

## Optimización de EBM's (iii)

Se ve claramente que la gradiente del logaritmo de la función de partición requiere que trabajemos con una esperanza sobre nuestra distribución parametrizada lo que desemboca una dependencia circular en nuestro modelo.

Todo lo mencionado motiva a buscar un enfoque diferente que no dependa de la función de partición o en otras palabras: Que **NO** dependamos de la normalización.

### *Observación:*

Se paso la gradiente dentro de la integral, pero esto se requiere de verificar mediante **la regla de Leibniz**. Los detalles y la demostración de dicha propiedad extrapolan el alcance de la presentación, pero para más información visitar los siguientes recursos:

- <https://math.stackexchange.com/questions/3131845/interchange-the-order-of-integral-and-derivative>
- [https://en.wikipedia.org/wiki/Leibniz\\_integral\\_rule](https://en.wikipedia.org/wiki/Leibniz_integral_rule)


## 2. Score Matching

## ¿Qué es el score?

Sea  $p(x)$  una función de densidad de probabilidad en  $\mathbb{R}^D$  la función score es la gradiente del logaritmo de la densidad:

$$\mathbf{s}(\mathbf{x}) := \nabla_{\mathbf{x}} \log p(\mathbf{x}) \quad \mathbf{s} : \mathbb{R}^D \rightarrow \mathbb{R}^D$$

Así, el score forma un campo vectorial que apunta a las regiones de mayor probabilidad dentro de la función de densidad de probabilidad.



# ¿Por qué trabajar con el score?

## 1. Libertad de la constante de normalización:

Como vimos en nuestra distribución de un modelo basado en energía y en muchas otras distribuciones existentes, tenemos que lidiar con un término de normalización que dote a una función de la propiedad particular de las funciones de densidad de probabilidad.

De manera general, veamos que:

$$p(\mathbf{x}) = \frac{\tilde{p}(\mathbf{x})}{Z} \quad Z = \int \tilde{p}(\mathbf{x}) \, d\mathbf{x}$$

Ahora computar dicho  $Z$  es intratable, pero al usar la función **score** vemos que:

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}) = \nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x}) - \underbrace{\nabla_{\mathbf{x}} \log Z}_0 = \nabla_{\mathbf{x}} \log \tilde{p}(\mathbf{x})$$

## ¿Por qué trabajar con el score? (ii)

### 2. Obtenemos una representación completa de $p(\mathbf{x})$

Podemos demostrar que el trabajar con la función **score** nos permite obtener una caracterización completa de la distribución original usando el **Teorema fundamental del cálculo**.

Sea  $u(t) : \mathbb{R} \rightarrow \mathbb{R}^D \Rightarrow \mathbf{x} + t(\mathbf{x}_0 - \mathbf{x})$  y  $g(\mathbf{x}) : \mathbb{R}^D \rightarrow \mathbb{R} \Rightarrow \log p(\mathbf{x})$ , podemos usar la **regla del cadena** para calcular:

$$\begin{aligned}\frac{d}{dt}g(u(t)) &= d\frac{g(u)}{du} \cdot d\frac{u(t)}{dt} \\ &= (\nabla_u \log p(u))^\top \cdot (\mathbf{x}_0 - \mathbf{x}) \\ &= (\mathbf{s}(u))^\top \big|_{u=\mathbf{x}+t(\mathbf{x}_0-\mathbf{x})} (x_0 - x)\end{aligned}$$

Ahora con el T.F.C se cumple lo siguiente:

$$\int_0^1 \frac{d}{dt}g(u(t)) dt = g(u(1)) - g(u(0)) = \log p(\mathbf{x}) - \log p(\mathbf{x}_0)$$

## ¿Por qué trabajar con el score? (iii)

Finalmente si combinamos nuestros resultados, obtendremos:

$$\log p(\mathbf{x}) - \log p(\mathbf{x}_0) = \int_0^1 \frac{d}{dt} g(u(t)) dt = \int_0^1 (\mathbf{s}(u))^\top \big|_{u=\mathbf{x}+t(\mathbf{x}_0-\mathbf{x})} (x_0 - x)$$

En conclusión se ve que podemos obtener una representación completa de  $p(\mathbf{x})$  como:

$$\begin{aligned} \log p(\mathbf{x}) - \log p(\mathbf{x}_0) &= \int_0^1 (\mathbf{s}(u))^\top \big|_{u=\mathbf{x}+t(\mathbf{x}_0-\mathbf{x})} (x_0 - x) \\ \log p(\mathbf{x}) &= \log p(\mathbf{x}_0) + \int_0^1 (\mathbf{s}(u))^\top \big|_{u=\mathbf{x}+t(\mathbf{x}_0-\mathbf{x})} (x_0 - x) \quad \blacksquare \end{aligned}$$

# Entrenamiento de EBMs mediante Score Matching

Es hora de entender *¿Qué es el Score Matching?*, basándonos en el paper de [1] es un método que busca minimizar la **divergencia de Fisher** de las distribuciones modeladas y la distribución desconocida de los datos. Esta divergencia es importante, ya que el paper original modelan un objetivo de la siguiente forma:

$$J(\phi) = \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \left\| \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) \right\|_2^2 \right]$$

Que en otras palabras resulta ser:

$$J(\phi) = \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \left\| \mathbf{s}_{\phi}(\mathbf{x}) - \mathbf{s}(\mathbf{x}) \right\|_2^2 \right]$$

Donde  $\mathbf{s}_{\phi}(\mathbf{x})$  es nuestra estimación de la función score mediante nuestra estimación de la función de energía, osea:

$$\mathbf{s}_{\phi}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}) = \nabla_{\mathbf{x}} \log \tilde{p}_{\phi}(\mathbf{x}) = \nabla_{\mathbf{x}} \log \exp(-E_{\phi}(\mathbf{x})) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}) \quad \blacksquare$$

## Entrenamiento de EBM's mediante Score Matching (ii)

### Primer Teorema

Asumiendo que la función de **score** es *diferenciable*, así como condiciones de regularidad débiles siendo estas en particular:

- Que la función de densidad de probabilidad  $p(\mathbf{x})$  sea *diferenciable*
- Se cumple que  $\mathbb{E}[\|\mathbf{s}_\phi(\mathbf{x})\|^2] < \infty$  y  $\mathbb{E}[\|\mathbf{s}(\mathbf{x})\|^2] < \infty$
- $\lim_{\|\mathbf{x}\| \rightarrow \infty} p(\mathbf{x})\mathbf{s}_\phi(\mathbf{x}) = 0$

Entonces la función objetivo  $J$  puede expresarse como:

$$J(\phi) = \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \text{tr}(\nabla_{\mathbf{x}}^2 E_\phi(\mathbf{x})) + \frac{1}{2} \|\nabla_{\mathbf{x}} E_\phi(\mathbf{x})\|_2^2 \right] + C$$

## Entrenamiento de EBMs mediante Score Matching (iii)

### *Demostración*

Podemos expandir  $J$  como:

$$\begin{aligned} J(\phi) &= \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 - \langle \mathbf{s}_{\phi}(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle + \|\mathbf{s}(\mathbf{x})\|_2^2 \right] \\ &= \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 \right] - \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\langle \mathbf{s}_{\phi}(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle] + \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}(\mathbf{x})\|_2^2] \end{aligned}$$

De esta expansión podemos ver que el tercer término pasa a ser una constante  $C$ , ya que no contiene ninguna dependencia con  $\phi$  y el primer término corresponde automáticamente al resultado del teorema si expandimos  $\mathbf{s}_{\phi}(\mathbf{x})$  como:

$$\frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2] = \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\|-\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x})\|_2^2] = \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\|\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x})\|_2^2]$$

## Entrenamiento de EBM's mediante Score Matching (iv)

Ahora nos enfocamos al segundo término con el producto escalar presente como:

$$\begin{aligned} -\mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\langle \mathbf{s}_\phi(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle] &= - \int \mathbf{s}_\phi(\mathbf{x})^\top \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) p_{\text{data}}(\mathbf{x}) \, d\mathbf{x} \\ &= - \int \mathbf{s}_\phi(\mathbf{x})^\top \frac{\nabla_{\mathbf{x}} p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x})} p_{\text{data}}(\mathbf{x}) \, d\mathbf{x} \\ &= - \int \mathbf{s}_\phi(\mathbf{x})^\top \nabla_{\mathbf{x}} p_{\text{data}}(\mathbf{x}) \, d\mathbf{x} \\ &= - \int \sum_{i=1}^D \mathbf{s}_\phi^{(i)}(\mathbf{x}) \frac{\partial p_{\text{data}}(\mathbf{x})}{\partial \mathbf{x}_i} \, d\mathbf{x} \\ &= - \sum_{i=1}^D \int \mathbf{s}_\phi^{(i)}(\mathbf{x}) \frac{\partial p_{\text{data}}(\mathbf{x})}{\partial \mathbf{x}_i} \, d\mathbf{x} \end{aligned}$$

El intercambio del símbolo de la integral con la sumatoria va de la mano con el **teorema de Fubini-Tonelli**, ya que  $\mathbf{s}_\phi^{(i)}(\mathbf{x}) \frac{\partial p_{\text{data}}(\mathbf{x})}{\partial \mathbf{x}_i} > 0$ .

# Entrenamiento de EBM's mediante Score Matching (v)

## ***Lema:***

Asumiendo que dos funciones  $f$  y  $g$  son diferenciables. Considerando un caso base de índice  $i = 1$  para todos los elementos de  $\mathbf{x}_i$ , se cumple que:

$$\lim_{a \rightarrow \infty, b \rightarrow -\infty} f(a, \mathbf{x}_2, \dots, \mathbf{x}_n)g(a, \mathbf{x}_2, \dots, \mathbf{x}_n) - f(b, \mathbf{x}_2, \dots, \mathbf{x}_n)g(b, \mathbf{x}_2, \dots, \mathbf{x}_n) = \int_{-\infty}^{\infty} f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}_1} d\mathbf{x} + \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_1} g(\mathbf{x}) d\mathbf{x}$$

## ***Mini demostración***

Recordando la regla de derivación para la multiplicación:

$$\frac{\partial [f(\mathbf{x})g(\mathbf{x})]}{\partial \mathbf{x}_1} = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_1} g(\mathbf{x}) + f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}_1}$$

## Entrenamiento de EBMs mediante Score Matching (vi)

Ahora integramos a ambas partes por todo el espacio  $\mathbb{R}$ , o equivalentemente  $(-\infty, \infty)$ , entonces:

$$\int_{-\infty}^{\infty} \frac{\partial [f(\mathbf{x})g(\mathbf{x})]}{\partial \mathbf{x}_1} d\mathbf{x} = \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}_1} g(\mathbf{x}) d\mathbf{x} + \int_{-\infty}^{\infty} f(\mathbf{x}) \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}_1} d\mathbf{x}$$

Usando **FTC** en el primer término, obtenemos lo siguiente:

$$\begin{aligned} \int_{-\infty}^{\infty} \frac{\partial [f(\mathbf{x})g(\mathbf{x})]}{\partial \mathbf{x}_1} d\mathbf{x} &= [f(\mathbf{x}_1^*, \mathbf{x}_2, \dots, \mathbf{x}_n)g(\mathbf{x}_1^*, \mathbf{x}_2, \dots, \mathbf{x}_n)]_{-\infty}^{\infty} \\ &= \lim_{a \rightarrow \infty, b \rightarrow -\infty} f(a, \mathbf{x}_2, \dots, \mathbf{x}_n)g(a, \mathbf{x}_2, \dots, \mathbf{x}_n) - f(b, \mathbf{x}_2, \dots, \mathbf{x}_n)g(b, \mathbf{x}_2, \dots, \mathbf{x}_n) \end{aligned}$$

Aunque se haya probado solo para  $i = 1$ , la propiedad se cumple en  $\forall i \in [1, n]$ .

## Entrenamiento de EBM's mediante Score Matching (vii)

Una vez visto el Lema, podemos aplicarlo a nuestra demostración reemplazando las funciones  $f(\mathbf{x})$  por  $\mathbf{s}_\phi^{(i)}(\mathbf{x})$  y  $g(\mathbf{x})$  por  $p_{\text{data}}(\mathbf{x})$  considerando nuestras condiciones iniciales, ambas son diferenciables.

$$\int_{\mathbb{R}} \frac{\partial [\mathbf{s}_\phi^{(i)}(\mathbf{x}) p_{\text{data}}(\mathbf{x})]}{\partial \mathbf{x}_i} d\mathbf{x} = \int_{\mathbb{R}} \frac{\partial \mathbf{s}_\phi^{(i)}(\mathbf{x})}{\partial \mathbf{x}_i} p_{\text{data}}(\mathbf{x}) d\mathbf{x} + \int_{\mathbb{R}} \mathbf{s}_\phi^{(i)}(\mathbf{x}) \frac{\partial p_{\text{data}}(\mathbf{x})}{\partial \mathbf{x}_i} d\mathbf{x}$$

Si desarrollamos la sección izquierda:

$$\begin{aligned} \int_{\mathbb{R}} \frac{\partial [\mathbf{s}_\phi^{(i)}(\mathbf{x}) p_{\text{data}}(\mathbf{x})]}{\partial \mathbf{x}_i} d\mathbf{x} &= \left[ \mathbf{s}_\phi^{(i)}(\mathbf{x}_1^*, \mathbf{x}_2, \dots, \mathbf{x}_D) p_{\text{data}}(\mathbf{x}_1^*, \mathbf{x}_2, \dots, \mathbf{x}_D) \right]_{-\infty}^{\infty} \\ &= 0 \end{aligned}$$

Entonces:

$$\int_{\mathbb{R}} \frac{\partial \mathbf{s}_\phi^{(i)}(\mathbf{x})}{\partial \mathbf{x}_i} p_{\text{data}}(\mathbf{x}) d\mathbf{x} = - \int_{\mathbb{R}} \mathbf{s}_\phi^{(i)}(\mathbf{x}) \frac{\partial p_{\text{data}}(\mathbf{x})}{\partial \mathbf{x}_i} d\mathbf{x}$$

## Entrenamiento de EBMs mediante Score Matching (viii)

Si lo reemplazamos en la expresión original:

$$\begin{aligned} -\mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\langle \mathbf{s}_\phi(\mathbf{x}), \mathbf{s}(\mathbf{x}) \rangle] &= -\sum_{i=1}^D \int \mathbf{s}_\phi^{(i)}(\mathbf{x}) \frac{\partial p_{\text{data}}(\mathbf{x})}{\partial \mathbf{x}_i} d\mathbf{x} \\ &= \sum_{i=1}^D \int \frac{\partial \mathbf{s}_\phi^{(i)}(\mathbf{x})}{\partial \mathbf{x}_i} p_{\text{data}}(\mathbf{x}) d\mathbf{x} \\ &= \sum_{i=1}^D \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \frac{\partial \mathbf{s}_\phi^{(i)}(\mathbf{x})}{\partial \mathbf{x}_i} \right] \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})} [\text{tr}(\nabla_{\mathbf{x}}^2 E_\phi(\mathbf{x}))] \end{aligned}$$

Finalmente, si juntamos todos nuestros resultados, obtendremos lo siguiente:

$$J(\phi) = \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \text{tr}(\nabla_{\mathbf{x}}^2 E_\phi(\mathbf{x})) + \frac{1}{2} \|\nabla_{\mathbf{x}} E_\phi(\mathbf{x})\|_2^2 \right] + C$$

# Entrenamiento de EBM's mediante Score Matching (ix)

## Segundo Teorema

Asumiendo que nuestro modelo parametrizado  $p_{\phi^*}(\mathbf{x}) \approx p(\mathbf{x})$  para algún  $\phi^*$ , tal que no exista otro valor paramétrico que estime una distribución igual (de acuerdo al medida de Lebesgue es decir, igual *en casi todo punto*) y que  $\tilde{p}_{\phi}(\mathbf{x}) > 0$  para todo  $\phi$  y  $\mathbf{x}$ , entonces:

$$J(\phi) = 0 \iff \phi = \phi^*$$

# Entrenamiento de EBMs mediante Score Matching ( $\mathbf{x}$ )

## *Demostración*

( $\Rightarrow$ ) Sea  $J(\phi) = 0$ . Dado que el integrando es no negativo, esto implica:

$$\frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ \|\mathbf{s}_{\phi}(\mathbf{x}) - \mathbf{s}(\mathbf{x})\|_2^2 \right] = \frac{1}{2} \int p_{\text{data}}(\mathbf{x}) \|\mathbf{s}_{\phi}(\mathbf{x}) - \mathbf{s}(\mathbf{x})\|_2^2 d\mathbf{x} = 0$$

Para que una integral de un integrando no negativo sea cero, se requiere que el integrando sea cero Lebesgue-c.t.p., es decir:

$$p_{\text{data}}(\mathbf{x}) \cdot \|\mathbf{s}_{\phi}(\mathbf{x}) - \mathbf{s}(\mathbf{x})\|_2^2 = 0 \quad \text{Lebesgue-c.t.p.}$$

Ahora bien, por hipótesis  $\tilde{p}_{\phi}(\mathbf{x}) > 0$  para todo  $\phi$  y  $\mathbf{x}$ ; eso implica que  $p_{\phi}(\mathbf{x}) > 0$  para todo  $\phi$  y  $\mathbf{x}$ , esto incluye a  $\phi^*$ . Como por hipótesis  $p_{\phi^*} \approx p_{\text{data}}$ , se concluye que  $p_{\text{data}}(\mathbf{x}) > 0$  para todo  $\mathbf{x}$ , lo que fuerza:

$$\|\mathbf{s}_{\phi}(\mathbf{x}) - \mathbf{s}(\mathbf{x})\|_2^2 = 0 \quad \text{Lebesgue-c.t.p.}$$

## Entrenamiento de EBM's mediante Score Matching (xi)

Por la diferenciabilidad asumida de la función score (que implica continuidad), esto se extiende a todo punto:

$$\mathbf{s}_\phi(\mathbf{x}) = \mathbf{s}(\mathbf{x}) \quad \forall \mathbf{x} \in \mathbb{R}^D$$

Desenvolviendo la función **score**:

$$\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}) = \nabla_{\mathbf{x}} \log p(\mathbf{x})$$

Integrando sobre  $\mathbb{R}^D$  (dominio conexo), existe una constante global  $c \in \mathbb{R}$  tal que:

$$\int_{\mathbb{R}^D} \nabla_{\mathbf{x}} (\log p_\phi(\mathbf{x}) - \log p(\mathbf{x})) \, d\mathbf{x} = \int_{\mathbb{R}^D} 0 \, d\mathbf{x}$$

$$\log p_\phi(\mathbf{x}) - \log p(\mathbf{x}) = c$$

$$\log p_\phi(\mathbf{x}) = \log p(\mathbf{x}) + c$$

## Entrenamiento de EBMs mediante Score Matching (xii)

Como  $p_\phi$  y  $p$  son ambas funciones de densidad de probabilidad, se cumple:

$$\int_{\mathbb{R}^D} p_\phi(\mathbf{x}) \, d\mathbf{x} = \int_{\mathbb{R}^D} e^c p(\mathbf{x}) \, d\mathbf{x} = e^c = 1 \Rightarrow c = 0$$

Por lo tanto  $p_\phi = p_{\text{data}} = p_\phi^*$ , y por la hipótesis de unicidad del modelo se concluye  $\phi = \phi^*$ . ■

( $\Leftarrow$ ) Es inmediato: si  $\phi = \phi^*$ , entonces  $p_\phi = p_{\text{data}}$ , luego  $\mathbf{s}_\phi = \mathbf{s}$  y así  $J(\phi) = 0$ . ■

### **3. Dinámica de Langevin**

## ¿Cómo surge?

Partiendo desde una perspectiva física, donde  $E_\phi(\mathbf{x})$  define un campo de potenciales que forman el comportamiento de partículas. De acuerdo a la dinámica Newtoniana, el movimiento de una partícula bajo un campo de fuerza derivado de la energía es descrita bajo la **ODE (Ordinary Differential Equation)**:

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_\phi(\mathbf{x}(t)) dt$$

Similar a un típico descenso de gradiente determinista, donde las partículas buscan un estado estable (menos energía); sin embargo, este determinismo puede resultar atrapado en un mínimo local que previene la exploración de toda la distribución final.

Para resolverlo, se introdujeron la dinámica de Langevin donde se introduce perturbaciones estocásticas que resultan en una **SDE (Stochastic Differential Equation)**:

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_\phi(\mathbf{x}(t)) dt + \sigma d\mathbf{w}(t)$$

Donde  $\mathbf{w}(t)$  es **movimiento Browniano** estándar.

## ¿Cómo surge? (ii)

Ese factor  $\sigma$  modela la intensidad del ruido estocástico, es decir, cuánta exploración estocástica se le permite a la partícula sobre el paisaje de energía.

La dinámica de Langevin no describe la trayectoria de una partícula individual, sino que induce una **densidad de probabilidad**  $\rho(\mathbf{x}, t)$  que representa la probabilidad de encontrar la partícula en la posición  $\mathbf{x}$  al tiempo  $t$ .

La evolución de esta densidad está gobernada por la **ecuación de Fokker-Planck**:

$$\frac{\partial \rho(\mathbf{x}, t)}{\partial t} = -\nabla \cdot (\mu(\mathbf{x})\rho(\mathbf{x}, t)) + \frac{\sigma^2}{2} \Delta \rho(\mathbf{x}, t)$$

Donde  $\mu(\mathbf{x}) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x})$  es el término de **arrastre**, mientras que  $\frac{\sigma^2}{2} \Delta \rho(\mathbf{x}, t)$  es el término de **difusión**.

## ¿Cómo surge? (iii)

En estado estacionario ( $\partial\rho(\mathbf{x}, t)/\partial t = 0$ ), la densidad transiente  $\rho(\mathbf{x}, t)$  converge a una distribución límite. Buscamos que dicha distribución límite coincida con  $p_\phi(\mathbf{x})$ ; esto ocurre si y solo si  $\sigma = \sqrt{2}$ , lo cual se verifica sustituyendo  $\mu(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_\phi(\mathbf{x})$  y  $\rho = p_\phi$  directamente en la ecuación de Fokker-Planck:

$$\begin{aligned} 0 &= -\nabla \cdot (\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x}) p_\phi(\mathbf{x})) + \frac{\sigma^2}{2} \Delta p_\phi(\mathbf{x}) \\ &= \underbrace{-\nabla \cdot (\nabla_{\mathbf{x}} p_\phi(\mathbf{x}))}_{-\nabla^2 p_\phi(\mathbf{x})} + \frac{\sigma^2}{2} \Delta p_\phi(\mathbf{x}) \\ &= -\Delta p_\phi(\mathbf{x}) + \frac{\sigma^2}{2} \Delta p_\phi(\mathbf{x}) \\ &= \underbrace{\left(-1 + \frac{\sigma^2}{2}\right)}_0 \Delta p_\phi(\mathbf{x}) \quad \therefore \sigma = \sqrt{2} \end{aligned}$$

# Dinámica de Langevin en tiempos continuo y discreto

Sin darnos cuenta, acabamos de definir precisamente la ***dinámica de Langevin en tiempo continuo***:

$$d\mathbf{x}(t) = \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}(t)) dt + \sqrt{2} d\mathbf{w}(t)$$

Aunque interesante, no resulta ser útil en la práctica más específico por la forma de resolver dicho **SDE** computacionalmente y para este lo convertiremos a la ***dinámica de Langevin en tiempo discreto***.

Para esta tarea usaremos del método de **Euler-Maruyama** sobre la **SDE continua** con un paso  $\eta > 0$ , dentro de esta discretización se especifica que los incrementos brownianos cuentan con la siguiente distribución:

$$\begin{aligned}\mathbf{w}(t + \eta) - \mathbf{w}(t) &\sim \mathcal{N}(\mathbf{0}, \eta \mathbf{I}) \\ \mathbf{w}(t + \eta) - \mathbf{w}(t) &= \sqrt{\eta} \varepsilon_n \sim \mathcal{N}(\mathbf{0}, \eta \mathbf{I}), \quad \varepsilon_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})\end{aligned}$$

## Dinámica de Langevin en tiempos continuo y discreto (ii)

Así finalmente nuestra discretización se convierte a:

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}(t)) + \sqrt{2\eta} \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad \blacksquare$$

# Limitaciones del muestreo de Langevin

A pesar de la garantía teórica de convergencia, en la práctica surgen problemas serios:

## Problemas principales:

- **Tiempo de mezcla lento:** distribuciones multimodales requieren tiempo exponencial para transicionar entre modos
- **Sensibilidad a hiperparámetros:**  $\eta$  y la escala del ruido requieren ajuste fino
- **Maldición de la dimensionalidad:** eficiencia cae al crecer  $D$

## **4. Referencias**

# Referencias

- A. Hyvärinen, «Estimation of Non-Normalized Statistical Models by Score Matching», *Journal of Machine Learning Research*, vol. 6, pp. 695-709, 2005, [En línea]. Disponible en: <https://jmlr.org/papers/volume6/hyvarinen05a/hyvarinen05a.pdf>
- [1]
- C.-H. Lai, Y. Song, D. Kim, Y. Mitsufuji, y S. Ermon, «The Principles of Diffusion Models: From Origins to Advances». [En línea]. Disponible en: <https://arxiv.org/abs/2510.21890>
- [2]
- S. Lyu, «Interpretation and Generalization of Score Matching». [En línea]. Disponible en: <https://arxiv.org/abs/1205.2629>
- [3]
- A. Jones, «Score Matching». [En línea]. Disponible en: <https://andrewcharlesjones.github.io/journal/21-score-matching.html>
- [4]