

Desde VAEs hasta DDPM

Un vistazo a los modelos generativos

03.03.2026

Ángel Aarón Flores Alberca



Índice

1. Preliminares de teoría de la información y modelos generativos	4
1.1. Objetivo de modelos generativos	5
1.2. Conceptos de teoría de la probabilidad	6
1.3. Conceptos de teoría de la información	7
1.4. Optimización de modelos generativos	10
2. Variational Autoencoders (VAEs)	11
2.1. ¿Cómo surgen los VAEs?	12
2.2. Construcción de un VAE	13
2.2.1. Decoder (Generador)	13
2.2.2. Encoder	14
2.3. Cálculo de cota para optimización	15
2.4. Interpretación informática del ELBO	17
2.5. VAE gaussiano	21
2.6. Problemas con VAEs	25
3. Denoising Diffusion Probabilistic Models (DDPM)	28
3.1. ¿Qué es DDPM?	29

Índice (ii)

3.2.	Forward process	30
3.3.	Recursividad y límite en el forward process	31
3.4.	Backward process	34
3.5.	NELBO del DDPM	37
3.6.	Relación entre divergencia marginal y condicional	43
3.7.	Reverso del kernel de transición	49
3.8.	Modelamiento del objetivo generador	58
3.9.	Formas prácticas de modelación	63
3.10.	Muestreo de nuevos datos	68
3.11.	Problemas con DDPM	69
4.	Referencias	70
4.1.	Referencias	71

1. Preliminares de teoría de la información y modelos generativos

Objetivo de modelos generativos

A partir de un dataset de observaciones asumidas como provenientes de una distribución desconocida p_{data} , se construye un modelo en base a redes neuronales para estimar una distribución de probabilidad p_{ϕ} donde ϕ representen los parámetros entrenables de la red neuronal.

El objetivo del entrenamiento es encontrar ϕ^* tal que minimice la divergencia entre la distribución del modelo p_{ϕ} y p_{data} , conceptualmente:

$$p_{\phi^*} \approx p_{\text{data}}$$
$$\phi^* \in \arg \min_{\phi} \mathcal{D}(p_{\text{data}}, p_{\phi})$$

Nota:

Dado que p_{data} resulta ser desconocido, el tipo de divergencia a elegirse debe estimar eficientemente de un muestreo de dicha distribución

Conceptos de teoría de la probabilidad

Desigualdad de Jensen

Dado un espacio de probabilidad $(\Omega, \mathcal{A}, \mathbb{P})$, si X es una variable aleatoria real y φ una función convexa entonces

$$\varphi\left(\int_{\Omega} X \, d\mathbb{P}\right) \leq \int_{\Omega} \varphi \circ X \, d\mathbb{P} \quad \equiv \quad \varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi \circ X]$$

Así mismo si fuese φ una función cóncava entonces

$$\varphi\left(\int_{\Omega} X \, d\mathbb{P}\right) \geq \int_{\Omega} \varphi \circ X \, d\mathbb{P} \quad \equiv \quad \varphi(\mathbb{E}[X]) \geq \mathbb{E}[\varphi \circ X]$$

Conceptos de teoría de la información

Entropía y entropía cruzada

Sea una variable aleatoria X con función de densidad p . Se define la entropía de X como una medida de aleatoriedad asociada con la distribución de probabilidad de X ; matemáticamente:

$$\mathcal{H}(X) = -\mathbb{E}_{X \sim p}[\log p(X)] = - \int p(x) \log p(x) \, dx$$

Sean dos variables aleatorias X e Y con funciones de densidad p y q , respectivamente. Se define la entropía cruzada de la distribución p a q como la discrepancia de representar eventos de p en q :

$$\mathcal{H}(p, q) = -\mathbb{E}_{X \sim p}[\log q(X)] = - \int p(x) \log q(x) \, dx$$

Conceptos de teoría de la información (ii)

Divergencia Kullback-Leibler

Sean dos funciones de densidad de probabilidad p, q . Se define la divergencia Kullback-Leibler de q a p como medida de cuánto diverge la distribución de probabilidad q de otra distribución p , matemáticamente es:

$$\mathcal{D}_{\text{KL}}(p \parallel q) = \mathbb{E}_{x \sim p} \left[\log \frac{p(x)}{q(x)} \right] = \int p(x) \log \frac{p(x)}{q(x)} dx$$

Esta medida de divergencia contiene ciertas propiedades:

- Asimetría:
 - Nulidad reflexiva:
 - No negatividad:
- $$\mathcal{D}_{\text{KL}}(p \parallel q) \neq \mathcal{D}_{\text{KL}}(q \parallel p) \quad \mathcal{D}_{\text{KL}}(p \parallel p) = \mathbb{E}_{x \sim p} \left[\log \left(\frac{p(x)}{p(x)} \right) \right] = 0 \quad \mathcal{D}_{\text{KL}}(p \parallel q) \geq 0$$

Conceptos de teoría de la información (iii)

Podemos hallar una relación entre estos conceptos al desarrollar el término de la divergencia de Kullback-Leibler:

$$\begin{aligned}\mathcal{D}_{\text{KL}}(p \parallel q) &= \mathbb{E}_{x \sim p} \left[\log \frac{p(x)}{q(x)} \right] \\ &= \mathbb{E}_{x \sim p} [\log p(x)] - \mathbb{E}_{x \sim p} [\log q(x)] \\ &= \mathcal{H}(p, q) - \mathcal{H}(X) \quad \blacksquare\end{aligned}$$

Optimización de modelos generativos

Considerando nuestro objetivo de modelos generativos, buscamos reducir la divergencia de la distribución p_ϕ a p_{data} entonces queremos minimizar $\mathcal{D}_{\text{KL}}(p_{\text{data}} \parallel p_\phi)$, entonces:

$$\mathcal{D}_{\text{KL}}(p_{\text{data}} \parallel p_\phi) = \mathbb{E}_{x \sim p_{\text{data}}} [\log p_{\text{data}}(x)] - \mathbb{E}_{x \sim p_{\text{data}}} [\log p_\phi(x)] = \mathcal{H}(p_{\text{data}}, p_\phi) - \mathcal{H}(p_{\text{data}})$$

Dado que $\mathcal{H}(p_{\text{data}})$ es constante frente a los parámetros ϕ , llegamos a la siguiente equivalencia:

$$\begin{aligned} \min \mathcal{D}_{\text{KL}}(p_{\text{data}} \parallel p_\phi) &= \min \mathcal{H}(p_{\text{data}}, p_\phi) \\ &= \max \mathbb{E}_{x \sim p_{\text{data}}} [\log p_\phi(x)] \end{aligned}$$

Mediante el método de estimación de Monte Carlo vemos que:

$$\hat{\mathcal{L}}_{\text{MLE}}(\phi) = -\mathbb{E}_{x \sim p_{\text{data}}} [\log p_\phi(x)] = -\frac{1}{N} \sum_{i=1}^N \log p_\phi(x_i)$$

2. Variational Autoencoders (VAEs)

¿Cómo surgen los VAEs?

Se presenta una idea inicial de generación de datos realistas mediante los **autoencoders**. Estos son arquitecturas que consisten en dos partes fundamentales:

- Un **encoder** o codificador determinista que comprima un valor de entrada en una representación de baja dimensión en un denominado **espacio latente**
- Un **decoder** o decodificador determinista que es capaz de reconstruir el valor de entrada mediante el valor codificado.

Sin embargo, este enfoque resulta en una construcción de un espacio latente desestructurado incapaz de generar nueva información, para lo cual se crearon los **Variational Autoencoders (VAEs)** que resuelven el *problema* mediante la introducción de una estructura probabilística en el espacio latente




Figura 1: Arquitectura principal de un VAE, constituido de un encoder estocástico q_{θ} y un decoder p_{ϕ}

Construcción de un VAE

Contaremos con dos tipos de variables: variables objetivo x correspondientes a los datos que deseamos generar y variables latentes z correspondientes a un espacio donde se capturan datos y se forma una representación abstracta de las variables objetivo.

2.2.1. Decoder (Generador)

Su utilidad es la de transformar z al espacio de las variables objetivos x para lo que se modela una distribución $p_\phi(x|z)$, tal que si se requiere generar nuevos datos se pueden extraer muestras de la distribución conocida de $z \sim p_{\text{prior}}$ y decodificarlas a $x \sim p_\phi(x|z)$

Así es que el VAE define un modelo generativo frente a la siguiente verosimilitud marginal como:

$$p_\phi(x) = \int p_\phi(x|z)p(z) \, dz$$

Pero la integral presentada resulta ser **intratable** para un modelo, por lo que una optimización directa de máxima verosimilitud logarítmica requiere de un nuevo enfoque.

Construcción de un VAE (ii)

2.2.2. Encoder

Mediante la regla de Bayes podemos notar el siguiente resultado como un reemplazo para obtener nuestra distribución objetivo:

$$p_{\phi}(z|x) = \frac{p_{\phi}(x|z)p(z)}{p_{\phi}(x)}$$

Sin embargo, por lo aclarado anteriormente, como $p_{\phi}(x)$ resulta ser intratable, entonces $p_{\phi}(z|x)$ también lo será. En particular esta distribución nos lleva a preguntarnos, ¿qué valores latentes z son obtenidos dada una variable objetivo x ?

Una forma de solucionar esta problemática es mediante un nuevo estimador $q_{\theta}(z|x)$ tal que

$$q_{\theta}(z|x) \approx p_{\phi}(z|x)$$

Cálculo de cota para optimización

Evidence Lower Bound (ELBO) para VAEs

Para cualquier punto x , la verosimilitud logarítmica satisface que:

$$\log p_{\phi}(x) \geq \mathcal{L}_{\text{ELBO}}(\theta, \phi; x)$$

Donde el ELBO se define como

$$\mathcal{L}_{\text{ELBO}} = \underbrace{\mathbb{E}_{z \sim q_{\theta}(z|x)} [\log p_{\phi}(x|z)]}_{\text{Minimización de reconstrucción}} - \underbrace{\mathcal{D}_{\text{KL}}(q_{\theta}(z|x) \parallel p(z))}_{\text{Regularización latente}}$$

Prueba

En la siguiente diapositiva:

Cálculo de cota para optimización (ii)

$$\begin{aligned}\log p_\phi(x) &= \log \int p_\phi(x, z) \, dz = \log \int q_\theta(z|x) \frac{p_\phi(x, z)}{q_\theta(z|x)} \, dz \\&= \log \mathbb{E}_{z \sim q_\theta(z|x)} \left[\frac{p_\phi(x, z)}{q_\theta(z|x)} \right] \\&\geq \mathbb{E}_{z \sim q_\theta(z|x)} \left[\log \frac{p_\phi(x, z)}{q_\theta(z|x)} \right] = \mathbb{E}_{z \sim q_\theta(z|x)} [\log p_\phi(x, z)] - \mathbb{E}_{z \sim q_\theta(z|x)} [\log q_\theta(z|x)] \\&= \mathbb{E}_{z \sim q_\theta(z|x)} \left[\log \frac{p_\phi(x|z)p(z)}{q_\theta(z|x)} \right] \\&= \mathbb{E}_{z \sim q_\theta(z|x)} [\log p_\phi(x|z)] - \mathbb{E}_{z \sim q_\theta(z|x)} \left[\log \frac{q_\theta(z|x)}{p(z)} \right] \\&= \mathbb{E}_{z \sim q_\theta(z|x)} [\log p_\phi(x|z)] - \mathcal{D}_{\text{KL}}(q_\theta(z|x) \parallel p(z)) \quad \blacksquare\end{aligned}$$

Interpretación informática del ELBO

El objetivo o la pérdida **ELBO** tiene una interpretación natural dentro de la teoría de la información, recordemos que el objetivo de disminuir la divergencia KL busca asegurarnos que las distribuciones modeladas y la real sean lo más similares.

Las VAEs introducen dos distribuciones conjuntas dadas por sus componentes principales:

- La probabilidad conjunta generativa (Decoder)

$$p_{\phi}(x, z) = p(z)p_{\phi}(x|z) = p_{\phi}(x)p_{\phi}(z|x)$$

Describe cómo el modelo genera nuevos datos.

- La probabilidad conjunta de inferencia (Encoder)

$$q_{\theta}(x, z) = p_{\text{data}}(x)q_{\theta}(z|x)$$

Describe cómo el modelo representa datos en su espacio latente.

Veamos cómo podemos llegar a la siguiente desigualdad entre las siguientes divergencias:

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}(x) \parallel p_{\phi}(x)) \leq \mathcal{D}_{\text{KL}}(q_{\theta}(x, z) \parallel p_{\phi}(x, z))$$

Interpretación informática del ELBO (ii)

Para comprobar dicha desigualdad, solo necesitamos expandir nuestra divergencia de interés:

$$\begin{aligned}\mathcal{D}_{\text{KL}}(q_{\theta}(x, z) \parallel p_{\phi}(x, z)) &= \mathbb{E}_{(x, z) \sim q_{\theta}(x, z)} \left[\log \frac{q_{\theta}(x, z)}{p_{\phi}(x, z)} \right] \\&= \mathbb{E}_{x \sim p_{\text{data}}(x)} \left[\mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\log \frac{p_{\text{data}}(x) q_{\theta}(z|x)}{p_{\phi}(x) p_{\phi}(z|x)} \right] \right] \\&= \mathbb{E}_{x \sim p_{\text{data}}(x)} \left[\log \frac{p_{\text{data}}(x)}{p_{\phi}(x)} + \mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\log \frac{q_{\theta}(z|x)}{p_{\phi}(z|x)} \right] \right] \\&= \mathbb{E}_{x \sim p_{\text{data}}(x)} \left[\log \frac{p_{\text{data}}(x)}{p_{\phi}(x)} \right] + \mathbb{E}_{x \sim p_{\text{data}}(x)} [\mathcal{D}_{\text{KL}}(q_{\theta}(z|x) \parallel p_{\phi}(z|x))] \\&= \mathcal{D}_{\text{KL}}(p_{\text{data}}(x) \parallel p_{\phi}(x)) + \mathbb{E}_{x \sim p_{\text{data}}(x)} [\mathcal{D}_{\text{KL}}(q_{\theta}(z|x) \parallel p_{\phi}(z|x))]\end{aligned}$$

Interpretación informática del ELBO (iii)

Podemos ver que se despliega en dos términos donde:

- $\mathcal{D}_{\text{KL}}(p_{\text{data}}(x) \parallel p_{\phi}(x))$ Representa el error de modelado que deseamos minimizar
- $\mathbb{E}_{x \sim p_{\text{data}}(x)} [\mathcal{D}_{\text{KL}}(q_{\theta}(z|x) \parallel p_{\phi}(z|x))]$ Representa el error de la inferencia que se provoca cuando decidimos generar una aproximación para $p_{\phi}(z|x)$ con $q_{\theta}(z|x)$

Interpretación informática del ELBO (iv)

Además notemos lo siguiente, si consideramos la divergencia KL de nuestro error de inferencia veremos lo siguiente:

$$\begin{aligned}\mathcal{D}_{\text{KL}}(q_{\theta}(z|x) \parallel p_{\phi}(z|x)) &= \mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\log \frac{q_{\theta}(z|x)}{p_{\phi}(z|x)} \right] = \mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\log \frac{q_{\theta}(z|x)}{p_{\phi}(x, z)} p_{\phi}(x) \right] \\&= \mathbb{E}_{z \sim q_{\theta}(z|x)} [\log q_{\theta}(z|x)] - \mathbb{E}_{z \sim q_{\theta}(z|x)} [\log p_{\phi}(x, z)] + \mathbb{E}_{z \sim q_{\theta}(z|x)} [\log p_{\phi}(x)] \\&= \log p_{\phi}(x) - \left(\mathbb{E}_{z \sim q_{\theta}(z|x)} [\log p_{\phi}(x, z)] - \mathbb{E}_{z \sim q_{\theta}(z|x)} [\log q_{\theta}(z|x)] \right) \\&= \log p_{\phi}(x) - \mathcal{L}_{\text{ELBO}}\end{aligned}$$

Entonces vemos que el error de la inferencia es exactamente lo que diferencia a la verosimilitud logarítmica con la cota ELBO. **Entonces**, si maximizamos ELBO durante el entrenamiento, también estaremos minimizando la divergencia de nuestro estimador de inferencia.

VAE gaussiano

Una formulación típica para un VAE utiliza distribuciones gaussianas para ambas estructuras:

- **Encoder gaussiano:** Definimos $q_\theta(z|x)$ tal que

$$q_\theta(z|x) := \mathcal{N}(\mu_\theta(x), \text{diag}(\sigma_\theta^2(x)))$$

En la que tenemos a $\mu_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^d$ y $\sigma_\theta^2(x) : \mathbb{R}^D \rightarrow \mathbb{R}_+^d$ como las salidas deterministas obtenidas por el modelo encoder.

- **Decoder gaussiano:** Definimos $p_\phi(x|z)$ tal que

$$p_\phi(x|z) := \mathcal{N}(\mu_\phi(z), \sigma^2 I)$$

En la que tenemos a $\mu_\phi : \mathbb{R}^d \rightarrow \mathbb{R}^D$ como el resultado del modelo decoder junto a un hiperparámetro σ que controla su varianza.

VAE gaussiano (ii)

Bajo esta suposición, podemos redefinir la parte de reconstruir de ELBO como:

$$\begin{aligned}\mathbb{E}_{z \sim q_{\theta}(z|x)} [\log p_{\phi}(x|z)] &= \mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\log \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(\|x - \mu_{\phi}(z)\|^2)} \right] \\ &= \mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\log e^{-\frac{1}{2\sigma^2}(\|x - \mu_{\phi}(z)\|^2)} \right] + \mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\log \frac{1}{\sqrt{2\pi}\sigma} \right] \\ &= -\frac{1}{2\sigma^2} \mathbb{E}_{z \sim q_{\theta}(z|x)} [\|x - \mu_{\phi}(z)\|^2] + C\end{aligned}$$

Concluyéndose así que para la optimización de nuestro modelo gaussiano:

$$\begin{aligned}\min \mathcal{D}_{\text{KL}}(p_{\text{data}}(x) \parallel p_{\phi}) &\iff \max \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log p_{\phi}(x)] \approx \max \mathbb{E}_{x \sim p_{\text{data}}(x)} [\mathcal{L}_{\text{ELBO}}] \\ &\iff \max \mathbb{E}_{x \sim p_{\text{data}}} \left[-\frac{1}{2\sigma^2} \mathbb{E}_{z \sim q_{\theta}(z|x)} [\|x - \mu_{\phi}(z)\|^2] - \mathcal{D}_{\text{KL}}(q_{\theta}(z|x) \parallel p(z)) \right] \\ &\iff \min \mathbb{E}_{x \sim p_{\text{data}}} \left[\frac{1}{2\sigma^2} \mathbb{E}_{z \sim q_{\theta}(z|x)} [\|x - \mu_{\phi}(z)\|^2] + \mathcal{D}_{\text{KL}}(q_{\theta}(z|x) \parallel p(z)) \right]\end{aligned}$$

VAE gaussiano (iii)

Consideremos ahora que para dos distribuciones gaussianas, sus divergencia KL esta dada como:

$$\mathcal{D}_{\text{KL}}(\mathcal{N}(\mu_0, \Sigma_0) \parallel \mathcal{N}(\mu_1, \Sigma_1)) = \frac{1}{2} \left[\text{tr}(\Sigma_1^{-1} \Sigma_0) + (\mu_1 - \mu_0)^\top \Sigma_1^{-1} (\mu_1 - \mu_0) - d + \ln \frac{\det(\Sigma_1)}{\det(\Sigma_0)} \right]$$

Si trasladamos esto con nuestras previas distribuciones:

$$\begin{aligned} \mathcal{D}_{\text{KL}}(q_\theta(z|x) \parallel p(z)) &= \frac{1}{2} \left[\text{tr}(\text{diag}(\sigma_\theta^2(x))) + \|\mu_\theta(x)\|^2 - d + \ln \left(\frac{1}{\det(\text{diag}(\sigma_\theta^2(x)))} \right) \right] \\ &= \frac{1}{2} \left[\sum_{i=1}^d \sigma_{i,\theta}^2(x) + \sum_{i=1}^d \mu_{i,\theta}^2(x) - \sum_{i=1}^d 1 - \sum_{i=1}^d \ln \sigma_{i,\theta}^2(x) \right] \\ &= -\frac{1}{2} \left[\sum_{i=1}^d 1 + \ln \sigma_{i,\theta}^2(x) - \exp(\ln \sigma_{i,\theta}^2(x)) - \mu_{i,\theta}^2(x) \right] \end{aligned}$$

VAE gaussiano (iv)

Al asumir que nuestra solución óptima de mínimos cuadrados es la misma con o sin el factor $\frac{1}{2\sigma^2}$ obtenemos que nuestro objetivo final será:

$$\min \mathbb{E}_{x \sim p_{\text{data}}} \left[\mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\|x - \mu_{\phi}(z)\|^2 \right] - \frac{1}{2} \left[\sum_{i=1}^d 1 + \ln \sigma_{i,\theta}^2(x) - \exp(\ln \sigma_{i,\theta}^2(x)) - \mu_{i,\theta}^2(x) \right] \right] \quad \blacksquare$$

Problemas con VAEs

Por más *bonito* que todo ha sido por ahora, las VAEs presentan un problema muy importante: **Suelen producir resultados borrosos.**

Entendamos este efecto al considerar nuestra versión gaussiana de VAEs anterior, en esta vemos que al optimizar nuestro error de reconstrucción obtenemos la siguiente expresión:

$$\arg \min_{\mu} \mathbb{E}_{x \sim p_{\text{data}}} \left[\mathbb{E}_{z \sim q_{\theta}(z|x)} \left[\|x - \mu_{\phi}(z)\|^2 \right] \right]$$

Este es un problema de mínimos cuadrados para la función $\mu_{\phi}(z)$. La solución teórica que minimiza esta expresión es la **esperanza condicional**:

$$\mu_{\phi}^*(z) = \mathbb{E}_{x \sim q_{\theta}(x|z)}[x],$$

Problemas con VAEs (ii)

Aplicando la regla de Bayes:

$$q_{\theta}(x|z) = \frac{q_{\theta}(z|x)p_{\text{data}}(x)}{p(z)}$$

$$p(z) = \int p_{\text{data}}(x) \cdot q_{\theta}(z|x) \, dx = \mathbb{E}_{x \sim p_{\text{data}}(x)}[q_{\theta}(z|x)]$$

O equivalentemente:

$$\begin{aligned}\mu_{\phi}^*(z) &= \int q_{\theta}(x|z) \cdot x \, dx \\ &= \frac{\int q_{\theta}(z|x) \cdot p_{\text{data}}(x) \cdot x \, dx}{p(z)} \\ &= \frac{\mathbb{E}_{p_{\text{data}}(x)}[q_{\theta}(z|x) \cdot x]}{\mathbb{E}_{p_{\text{data}}(x)}[q_{\theta}(z|x)]} \quad \blacksquare\end{aligned}$$

Problemas con VAEs (iii)

Este resultado para la solución óptima teórica nos indica que el decoder deberá de producir un **promedio ponderado** de todos los x en el conjunto de datos, donde el peso de cada x es precisamente $q_{\theta}(z|x)$.

Ahora, supongamos que dos entradas distintas $x \neq x'$ son mapeadas por el encoder a regiones solapadas en el espacio latente. Esto significa que existe algún z tal que tanto $q_{\theta}(z|x) > 0$ como $q_{\theta}(z|x') > 0$. Entonces, para ese z , el decoder óptimo $\mu_{\phi}^*(z)$ será un promedio de x y x' y de otros pesos con peso no nulo.

Finalmente, obtenemos resultados con ruido que mezcla características y valores de las muestras de los datos de entrenamiento, siendo esta la razón fundamental de un efecto borroso en las nuevas muestras generadas.

3. Denoising Diffusion Probabilistic Models (DDPM)

¿Qué es DDPM?

Modelo de difusión que comprende un marco de trabajo variacional similar al de VAEs diferenciándose por la introducción de dos distintos procesos estocásticos:

- Forward process:

Proceso de corrupción de datos al inyectar ruido Gaussiano durante diferentes pasos mediante un **kernel de transición** $p(x_i|x_{i-1})$. Los datos se transforman en ruido puro, constituyendo la parte de codificación (encoder) fijo.

- Backward process:

Proceso de reconstrucción o **reversión de la corrupción del ruido** modelado mediante una red neuronal que estime una distribución parametrizada como $p_\phi(x_{i-1}|x_i)$.




Figura 2: Proceso de corrupción de datos (encoder) y el aprendizaje del proceso inverso (decoder) del DDPM.

Forward process

Proceso no entrenable de corrupción de datos que progresivamente añade ruido en múltiples pasos hasta transformarlo en una distribución probabilística, usualmente por conveniencia, gaussiana $p_{\text{prior}} := \mathcal{N}(0, I)$.

La degradación sucede al definir que para cada paso se modele un kernel de transición gaussiano definido como:

$$p(x_i | x_{i-1}) := \mathcal{N}\left(\sqrt{1 - \beta_i^2} x_{i-1}, \beta_i^2 I\right)$$

Se define la secuencia $\{\beta_i\}_{i=1}^L$ como monótona creciente con $\beta_i \in (0, 1)$ capaz de controlar el ruido gaussiano inyectado en el paso i . Por conveniencia podríamos denotar como $\alpha_i := \sqrt{1 - \beta_i^2}$, así por el **truco de la re parametrización** obtendríamos:

$$x_i = \alpha_i x_{i-1} + \beta_i \epsilon_i$$

donde $\epsilon_i \sim \mathcal{N}(0, I)$ son i.i.d.

Recursividad y límite en el forward process

Forma directa de corrupción en el paso i

Realizando el proceso recursivamente podemos llegar a una expresión simplificada y directa desde la muestra original x_0 hasta el objetivo en i pasos dado como:

$$p(x_i|x_0) = \mathcal{N}(\bar{\alpha}_i x_0, (1 - \bar{\alpha}_i^2)I)$$

$$\text{donde } \bar{\alpha}_i = \prod_{k=1}^i \alpha_k = \prod_{k=1}^i \sqrt{1 - \beta_k^2}.$$

Prueba

Consideremos la primera transición x_0 a x_1 definido como:

$$x_1 = \alpha_1 x_0 + \beta_1 \epsilon_1, \quad \epsilon_1 \sim \mathcal{N}(0, I)$$

Recursividad y límite en el forward process (ii)

Ahora lo reescribimos para la siguiente transición:

$$\begin{aligned}x_2 &= \alpha_2 x_1 + \beta_2 \epsilon_2 = \alpha_2 (\alpha_1 x_0 + \beta_1 \epsilon_1) + \beta_2 \epsilon_2 \\&= \alpha_2 \alpha_1 x_0 + \alpha_2 \beta_1 \epsilon_1 + \beta_2 \epsilon_2\end{aligned}$$

De aquí notaremos que $\alpha_2 \beta_1 \epsilon_1 \sim \mathcal{N}(0, \alpha_2^2 \beta_1^2)$ y $\beta_2 \epsilon_2 \sim \mathcal{N}(0, \beta_2^2)$, entonces

$$\alpha_2 \beta_1 \epsilon_1 + \beta_2 \epsilon_2 \sim \mathcal{N}(0, \alpha_2^2 \beta_1^2 + \beta_2^2)$$

Si desarrollamos el término de la varianza, veremos que:

$$\begin{aligned}\alpha_2^2 \beta_1^2 + \beta_2^2 &= (1 - \beta_2^2)(\beta_1^2) + \beta_2^2 \\&= -(\beta_2^2 - 1)(\beta_1^2) + (\beta_2^2 - 1) + 1 \\&= -\underbrace{(1 - \beta_2^2)}_{\alpha_2^2} \underbrace{(1 - \beta_1^2)}_{\alpha_1^2} + 1 \\&= 1 - \alpha_1^2 \alpha_2^2\end{aligned}$$

Recursividad y límite en el forward process (iii)

Al ir añadiendo más y más términos llegaremos a la forma general para un paso i de:

$$\begin{aligned}x_i &= \alpha_i \alpha_{i-1} \dots \alpha_2 \alpha_1 x_0 + \sqrt{1 - (\alpha_i \alpha_{i-1} \dots \alpha_2 \alpha_1)^2} \epsilon \quad \epsilon \sim \mathcal{N}(0, I) \\ &= \bar{\alpha}_i x_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon \quad \blacksquare\end{aligned}$$

Como consideramos nuestra serie de hiperparámetros $\{\beta_i\}_{i=1}^L$ es una sucesión creciente, entonces la distribución del proceso de corrupción converge:

$$p(x_L | x_0) \longrightarrow \mathcal{N}(0, I) \text{ cuando } L \rightarrow \infty$$

Backward process

La esencia de DDPM se centra en el proceso de revertir la degradación controlada dada por el proceso de corrupción inicial. Comenzamos de ruido puro de la distribución $x_L \sim \mathcal{N}(0, I)$ para luego revertir paso a paso la aleatoriedad hasta encontrarnos con una muestra de un dato significativo.

Entonces nos topamos con el siguiente problema:

¿Cómo podemos computar precisamente, o al menos aproximar, la inversa de los kernels de transición $p(x_{i-1}|x_i)$, especialmente si consideramos la intratable distribución de $x_i \sim p(x_i)$?

Backward process (ii)

Mediante el teorema de Bayes podemos cambiar la distribución objetivo como:

$$p(x_{i-1}|x_i) = p(x_i|x_{i-1}) \underbrace{\frac{p(x_{i-1})}{p(x_i)}}_{\text{intratables}}$$

Vemos que estas distribuciones marginales para x_i y x_{i-1} no son calculables dado que x_{data} es desconocido, podrían ser expresados de la siguiente forma:

$$p(x_i) = \int p(x_i|x_0)p_{\text{data}}(x_0) \mathrm{d}x_0 = \mathbb{E}_{x_0 \sim p_{\text{data}}} [p(x_i|x_0)]$$

Backward process (iii)

Así, condicionando las distribuciones, lo convertimos en *matemáticamente* tratable:

$$\begin{aligned} p(x_{i-1}|x_i, x_0) &= p(x_i|x_{i-1}, x_0) \frac{p(x_{i-1}|x_0)}{p(x_i|x_0)} \\ &= p(x_i|x_{i-1}) \frac{p(x_{i-1}|x_0)}{p(x_i|x_0)} \end{aligned}$$

Esto último se cumple gracias a la **propiedad de Markov** del proceso de corrupción donde x_i solo dependerá del último paso x_{i-1} :

$$p(x_i|x_{i-1}, x_0) = p(x_i|x_{i-1})$$

Así mismo también llegamos a la igualdad:

$$p(x_i, x_{i-1}|x_0) = p(x_{i-1}|x_i, x_0)p(x_i|x_0)$$

NELBO del DDPM

Negative Evidence Lower Bound (ELBO) para DDPM

Para cualquier muestra x_0 , la verosimilitud logarítmica satisface que

$$-\log p_\phi(x_0) \leq -\mathcal{L}_{\text{ELBO}}(\phi; x_0) := \mathcal{L}_{\text{prior}}(x_0) + \mathcal{L}_{\text{recons.}}(x_0; \phi) + \mathcal{L}_{\text{diffusion}}(x_0; \phi)$$

Donde cada componente se define como:

$$\mathcal{L}_{\text{prior}}(x_0) := \mathcal{D}_{\text{KL}}(p(x_L|x_0) \parallel p_{\text{prior}}(x_L))$$

$$\mathcal{L}_{\text{recons.}}(x_0; \phi) := \mathcal{H}(p(x_1|x_0), p_\phi(x_0|x_1))$$

$$\mathcal{L}_{\text{diffusion}}(x_0; \phi) := \sum_{i=2}^L \mathbb{E}_{x_i \sim p(x_i|x_0)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i))]$$

NELBO del DDPM (ii)

Prueba

De acuerdo a nuestro proceso esperado, lo que buscamos es que la definición de la probabilidad conjunta de la distribución generativa en DDPM sea definida como:

$$p_{\phi}(x_0, x_{1:L}) := p_{\phi}(x_0|x_1)p_{\phi}(x_1|x_2)\dots p_{\phi}(x_{L-1}|x_L)p_{\text{prior}}(x_L) = p_{\text{prior}}(x_L)p_{\phi}(x_0|x_1)\prod_{i=2}^L p_{\phi}(x_{i-1}|x_i)$$

tal que la distribución marginal generativa del modelo esté dada como:

$$p_{\phi}(x_0) := \int p_{\phi}(x_0, x_{1:L}) \mathrm{d}x_{1:L}$$

NELBO del DDPM (iii)

Ahora pasamos a buscar nuestra verosimilitud logarítmica con nuestra definición:

$$\begin{aligned}\log p_\phi(x_0) &= \log \int p_\phi(x_0, x_{1:L}) \mathrm{d}x_{1:L} \\&= \log \int p(x_{1:L}|x_0) \frac{p_\phi(x_0, x_{1:L})}{p(x_{1:L}|x_0)} \mathrm{d}x_{1:L} \\&= \log \mathbb{E}_{x_{1:L} \sim p(x_{1:L}|x_0)} \left[\frac{p_\phi(x_0, x_{1:L})}{p(x_{1:L}|x_0)} \right] \\&\geq \underbrace{\mathbb{E}_{x_{1:L} \sim p(x_{1:L}|x_0)} \left[\log \frac{p_\phi(x_0, x_{1:L})}{p(x_{1:L}|x_0)} \right]}_{\text{ELBO}} \\&\therefore -\log p_\phi(x_0) \leq -\mathbb{E}_{x_{1:L} \sim p(x_{1:L}|x_0)} \left[\log \frac{p_\phi(x_0, x_{1:L})}{p(x_{1:L}|x_0)} \right]\end{aligned}$$

NELBO del DDPM (iv)

Continuamos con la expansión de nuestro NELBO, al usar nuestra previa factorización, considerando ahora que esta condicionado con x_0

$$p(x_{1:L}|x_0) = p(x_1|x_2, x_0)p(x_2|x_3, x_0)\dots p(x_{L-1}|x_L, x_0)p(x_L|x_0) = p(x_L|x_0) \prod_{i=2}^L p(x_{i-1}|x_i, x_0)$$

Entonces ahora reemplazándolo en la expresión original tenemos

$$\begin{aligned} \log \frac{p_\phi(x_0, x_{1:L})}{p(x_{1:L}|x_0)} &= \log \frac{p_{\text{prior}}(x_L)p_\phi(x_0|x_1) \prod_{i=2}^L p_\phi(x_{i-1}|x_i)}{p(x_L|x_0) \prod_{i=2}^L p(x_{i-1}|x_i, x_0)} \\ &= \log p_{\text{prior}}(x_L) + \log p_\phi(x_0|x_1) + \sum_{i=2}^L \log p_\phi(x_{i-1}|x_i) - \log p(x_L|x_0) - \sum_{i=2}^L \log p(x_{i-1}|x_i, x_0) \end{aligned}$$

NELBO del DDPM (v)

Con nuestra expresión **negada** obtendremos la siguiente expresión:

$$\begin{aligned}\mathcal{L}_{\text{NELBO}} &= -\mathcal{L}_{\text{ELBO}} \\ &= -\mathbb{E}_{x_{1:L} \sim p(x_{1:L}|x_0)} \left[\log p_{\text{prior}}(x_L) + \log p_{\phi}(x_0|x_1) + \sum_{i=2}^L \log p_{\phi}(x_{i-1}|x_i) - \log p(x_L|x_0) - \sum_{i=2}^L \log p(x_{i-1}|x_i, x_0) \right] \\ &= \mathbb{E}_{x_{1:L} \sim p(x_{1:L}|x_0)} \left[\log p(x_L|x_0) - \log p_{\text{prior}}(x_L) - \log p_{\phi}(x_0|x_1) + \sum_{i=2}^L \log p(x_{i-1}|x_i, x_0) - \sum_{i=2}^L \log p_{\phi}(x_{i-1}|x_i) \right] \\ &= \mathbb{E}_{x_{1:L} \sim p(x_{1:L}|x_0)} \left[\log \frac{p(x_L|x_0)}{p_{\text{prior}}(x_L)} - \log p_{\phi}(x_0|x_1) + \sum_{i=2}^L \log \frac{p(x_{i-1}|x_i, x_0)}{p_{\phi}(x_{i-1}|x_i)} \right]\end{aligned}$$

NELBO del DDPM (vi)

Ahora cuando aplicamos la esperanza en la expresión separada por partes obtenemos:

$$\mathcal{L}_{\text{prior}} = \mathbb{E}_{x_L \sim p(x_L|x_0)} \left[\log \frac{p(x_L|x_0)}{p_{\text{prior}}(x_L)} \right] = \mathcal{D}_{\text{KL}}(p(x_L|x_0) \parallel p_{\text{prior}}(x_L))$$
$$\mathcal{L}_{\text{recons.}} = \mathbb{E}_{x_1 \sim p(x_1|x_0)} [-\log p_{\phi}(x_0|x_1)] = \mathcal{H}(p(x_1|x_0), p_{\phi}(x_0|x_1))$$

Se deriva en

$$\begin{aligned} \mathcal{L}_{\text{diffusion}} &= \mathbb{E}_{x_{1:L} \sim p(x_{1:L}|x_0)} \left[\sum_{i=2}^L \log \frac{p(x_{i-1}|x_i, x_0)}{p_{\phi}(x_{i-1}|x_i)} \right] = \sum_{i=2}^L \mathbb{E}_{(x_i, x_{i-1}) \sim p(x_i, x_{i-1}|x_0)} \left[\log \frac{p(x_{i-1}|x_i, x_0)}{p_{\phi}(x_{i-1}|x_i)} \right] \\ &= \sum_{i=2}^L \mathbb{E}_{x_i \sim p(x_i|x_0)} \mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log \frac{p(x_{i-1}|x_i, x_0)}{p_{\phi}(x_{i-1}|x_i)} \right] \\ &= \sum_{i=2}^L \mathbb{E}_{x_i \sim p(x_i|x_0)} \mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_{\phi}(x_{i-1}|x_i)) \end{aligned}$$

Relación entre divergencia marginal y condicional

Equivalencia de minimización entre divergencia KL marginal y condicional

Se tiene la siguiente igualdad:

$$\begin{aligned} & \mathbb{E}_{x_i \sim p_i(x_i)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i) \parallel p_\phi(x_{i-1}|x_i))] \\ &= \\ & \mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} \mathbb{E}_{x_i \sim p(x_i|x_0)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i))] + C \end{aligned}$$

Donde C es una constante independiente de ϕ , puntualmente la distribución objetivo que minimiza la ecuación tiene la forma:

$$p^*(x_{i-1}|x_i) = \mathbb{E}_{x_0 \sim p(x_0|x_i)} [p(x_{i-1}|x_i, x_0)] = p(x_{i-1}|x_i), \quad x_i \sim p_i$$

Relación entre divergencia marginal y condicional (ii)

Prueba

Partimos de la expresión de la derecha y expandimos su definición:

$$\begin{aligned} & \mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} \mathbb{E}_{x_i \sim p(x_i|x_0)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_{\phi}(x_{i-1}|x_i))] \\ &= \int \int p(x_0) p(x_i|x_0) \mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_{\phi}(x_{i-1}|x_i)) dx_0 dx_i \\ &= \int p(x_i) \int p(x_0|x_i) \mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_{\phi}(x_{i-1}|x_i)) dx_0 dx_i \end{aligned}$$

Ahora expandamos la definición de la divergencia KL:

$$\begin{aligned} \mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_{\phi}(x_{i-1}|x_i)) &= \mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log \frac{p(x_{i-1}|x_i, x_0)}{p_{\phi}(x_{i-1}|x_i)} \right] \\ &= \int p(x_{i-1}|x_i, x_0) \log \frac{p(x_{i-1}|x_i, x_0)}{p_{\phi}(x_{i-1}|x_i)} dx_{i-1} \end{aligned}$$

Relación entre divergencia marginal y condicional (iii)

Ahora al reemplazarlo todo junto tenemos el siguiente resultado:

$$\int p(x_i) \int p(x_0|x_i) \int p(x_{i-1}|x_i, x_0) \log \frac{p(x_{i-1}|x_i, x_0)}{p_\phi(x_{i-1}|x_i)} dx_{i-1} dx_0 dx_i$$

Lo reescribimos en su versión esperanza:

$$\mathbb{E}_{x_i \sim p(x_i)} \left[\mathbb{E}_{x_0 \sim p(x_0|x_i)} \left[\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log \frac{p(x_{i-1}|x_i, x_0)}{p_\phi(x_{i-1}|x_i)} \right] \right] \right]$$

Relación entre divergencia marginal y condicional (iv)

Expandimos la definición logarítmica mediante la siguiente equivalencia:

$$\begin{aligned}\log \frac{p(x_{i-1}|x_i, x_0)}{p_\phi(x_{i-1}|x_i)} &= \log \frac{p(x_{i-1}|x_i, x_0)p(x_{i-1}|x_i)}{p(x_{i-1}|x_i)p_\phi(x_{i-1}|x_i)} \\ &= \log \frac{p(x_{i-1}|x_i, x_0)}{p(x_{i-1}|x_i)} + \log \frac{p(x_{i-1}|x_i)}{p_\phi(x_{i-1}|x_i)}\end{aligned}$$

Cuando lo reemplazamos, logramos expandir nuestra expresión en dos partes siguientes

$$\mathbb{E}_{x_i \sim p(x_i)} \left[\mathbb{E}_{x_0 \sim p(x_0|x_i)} \left[\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log \frac{p(x_{i-1}|x_i, x_0)}{p(x_{i-1}|x_i)} + \log \frac{p(x_{i-1}|x_i)}{p_\phi(x_{i-1}|x_i)} \right] \right] \right]$$

Relación entre divergencia marginal y condicional (v)

En la segunda parte, notamos que ya no dependemos de x_0 por lo que se simplifica como:

$$\begin{aligned}\mathbb{E}_{x_i \sim p(x_i)} \left[\mathbb{E}_{x_0 \sim p(x_0|x_i)} \left[\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log \frac{p(x_{i-1}|x_i)}{p_\phi(x_{i-1}|x_i)} \right] \right] \right] &= \mathbb{E}_{x_i \sim p(x_i)} \left[\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i)} \left[\log \frac{p(x_{i-1}|x_i)}{p_\phi(x_{i-1}|x_i)} \right] \right] \\ &= \mathbb{E}_{x_i \sim p(x_i)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i) \parallel p_\phi(x_{i-1}|x_i))]\end{aligned}$$

Ahora para la primera parte tendríamos:

$$\begin{aligned}\mathbb{E}_{x_i \sim p(x_i)} \left[\mathbb{E}_{x_0 \sim p(x_0|x_i)} \left[\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log \frac{p(x_{i-1}|x_i, x_0)}{p(x_{i-1}|x_i)} \right] \right] \right] \\ = \mathbb{E}_{x_i \sim p(x_i)} \left[\mathbb{E}_{x_0 \sim p(x_0|x_i)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p(x_{i-1}|x_i))] \right]\end{aligned}$$

Relación entre divergencia marginal y condicional (vi)

Esta primera parte corresponde a un valor independiente de nuestros parámetros ϕ por lo que podríamos considerarlo con una constante C tal que conseguimos nuestro resultado final:

$$\mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} \mathbb{E}_{x_i \sim p(x_i|x_0)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i))] = \mathbb{E}_{x_i \sim p(x_i)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i) \parallel p_\phi(x_{i-1}|x_i))] + C \quad \blacksquare$$

Ahora para poder validar cual es nuestro minimizador, recordemos las propiedades de la divergencia KL tal que es **no negativa** y **nula reflexiva**, así el valor que minimice la expresión será:

$$\begin{aligned} p^*(x_{i-1}|x_i) &= p(x_{i-1}|x_i) = \int p(x_{i-1}, x_0|x_i) \mathrm{d}x_0 \\ &= \int p(x_0|x_i) p(x_{i-1}|x_i, x_0) \mathrm{d}x_0 \\ &= \mathbb{E}_{x_0 \sim p(x_0|x_i)} [p(x_{i-1}|x_i, x_0)] \quad \blacksquare \end{aligned}$$

Reverso del kernel de transición

Distribución condicional del reverso del kernel de transición

Sabemos que $p(x_{i-1}|x_i, x_0)$ es gaussiana con forma cerrada:

$$p(x_{i-1}|x_i, x_0) := \mathcal{N}(\mu(x_i, x_0, i), \sigma^2(i)I)$$

donde

$$\mu(x_i, x_0, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1 - \bar{\alpha}_i^2}x_0 + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2}x_i, \quad \sigma^2(i) := \frac{1 - \bar{\alpha}_{i-1}^2}{1 - \bar{\alpha}_i^2}\beta_i^2$$

Reverso del kernel de transición (ii)

Prueba

Consideremos entonces la forma obtenida para $p(x_{i-1}|x_i, x_0)$ dado como:

$$p(x_{i-1}|x_i, x_0) = p(x_i|x_{i-1}) \frac{p(x_{i-1}|x_0)}{p(x_i|x_0)}$$

Entonces, mediante las distribuciones definidas para el proceso de corrupción, podemos expandir la expresión como:

$$p(x_{i-1}|x_i, x_0) = \frac{\frac{1}{\sqrt{2\pi}\beta_i} \exp\left(-\frac{1}{2} \frac{(x_i - \alpha_i x_{i-1})^2}{\beta_i^2}\right) \frac{1}{\sqrt{2\pi}\sqrt{1-\bar{\alpha}_{i-1}^2}} \exp\left(-\frac{1}{2} \frac{(x_{i-1} - \bar{\alpha}_{i-1} x_0)^2}{1-\bar{\alpha}_{i-1}^2}\right)}{\frac{1}{\sqrt{2\pi}\sqrt{1-\bar{\alpha}_i^2}} \exp\left(-\frac{1}{2} \frac{(x_i - \bar{\alpha}_i x_0)^2}{1-\bar{\alpha}_i^2}\right)}$$

Reverso del kernel de transición (iii)

Desarrollando los coeficientes fuera de las exponenciales nos encontramos con:

$$\frac{\frac{1}{\sqrt{2\pi}\beta_i} \frac{1}{\sqrt{2\pi}\sqrt{1-\bar{\alpha}_{i-1}^2}}}{\frac{1}{\sqrt{2\pi}\sqrt{1-\bar{\alpha}_i^2}}} = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{\frac{1-\bar{\alpha}_{i-1}^2}{1-\bar{\alpha}_i^2}\beta_i^2}} \equiv \frac{1}{\sqrt{2\pi}\sigma}$$

Que satisface de cierta forma nuestro lema:

$$\sigma^2 = \frac{1 - \bar{\alpha}_{i-1}^2}{1 - \bar{\alpha}_i^2} \beta_i^2$$

Reverso del kernel de transición (iv)

Continuemos con las exponenciales tal que mediante las operaciones de producto y división tenemos que:

$$-\frac{1}{2} \left(\frac{(x_i - \alpha_i x_{i-1})^2}{\beta_i^2} + \frac{(x_{i-1} - \bar{\alpha}_{i-1} x_0)^2}{1 - \bar{\alpha}_{i-1}^2} - \frac{(x_i - \bar{\alpha}_i x_0)^2}{1 - \bar{\alpha}_i^2} \right)$$

Desarrollemos una forma cuadrada alrededor del término x_{i-1} considerando los dos primeros términos de la factorización:

$$\begin{aligned} & \frac{x_i^2 - 2\alpha_i x_i x_{i-1} + \alpha_i^2 x_{i-1}^2}{\beta_i^2} + \frac{x_{i-1}^2 - 2\bar{\alpha}_{i-1} x_{i-1} x_0 + \bar{\alpha}_{i-1}^2 x_0^2}{1 - \bar{\alpha}_{i-1}^2} \\ &= x_{i-1}^2 \left(\frac{\alpha_i^2}{\beta_i^2} + \frac{1}{1 - \bar{\alpha}_{i-1}^2} \right) - x_{i-1} \left(\frac{2\alpha_i x_i}{\beta_i^2} + \frac{2\bar{\alpha}_{i-1} x_0}{1 - \bar{\alpha}_{i-1}^2} \right) + \frac{x_i^2}{\beta_i^2} + \frac{\bar{\alpha}_{i-1}^2 x_0^2}{1 - \bar{\alpha}_{i-1}^2} \end{aligned}$$

Reverso del kernel de transición (v)

Separemos con variables a los siguientes términos y consideremos que:

$$A = \frac{\alpha_i^2}{\beta_i^2} + \frac{1}{1 - \bar{\alpha}_{i-1}^2}, \quad 2B = \frac{2\alpha_i x_i}{\beta_i^2} + \frac{2\bar{\alpha}_{i-1} x_0}{1 - \bar{\alpha}_{i-1}^2}, \quad C = \frac{x_i^2}{\beta_i^2} + \frac{\bar{\alpha}_{i-1}^2 x_0^2}{1 - \bar{\alpha}_{i-1}^2}$$

así mismo como $\alpha_i = \sqrt{1 - \beta_i^2}$, entonces $\alpha_i^2 + \beta_i^2 = 1$

Ahora, si desarrollásemos A , notaremos que:

$$A = \frac{\alpha_i^2}{\beta_i^2} + \frac{1}{1 - \bar{\alpha}_{i-1}^2} = \frac{\alpha_i^2 - \alpha_i^2 \bar{\alpha}_{i-1}^2 + \beta_i^2}{\beta_i^2 (1 - \bar{\alpha}_{i-1}^2)} = \frac{1 - \bar{\alpha}_{i-1}^2}{\beta_i^2 (1 - \bar{\alpha}_{i-1}^2)} = \frac{1}{\beta_i^2}$$

Reverso del kernel de transición (vi)

Antes de emocionarnos, lo primero que deberemos de hacer es completar los cuadrados dados en la expresión original como:

$$\begin{aligned} Ax_{i-1}^2 - 2Bx_{i-1} + C &= A \left(x_{i-1}^2 - 2\frac{B}{A}x_{i-1} + \frac{B^2}{A^2} - \frac{B^2}{A^2} \right) + C \\ &= A \left(x_{i-1} - \frac{B}{A} \right)^2 + C - \frac{B^2}{A} \end{aligned}$$

Podemos ir resolviendo poco a poco la expresión $C - \frac{B^2}{A}$ tal que:

$$\begin{aligned} B^2 &= \left(\frac{\alpha_i x_i}{\beta_i^2} + \frac{\bar{\alpha}_{i-1} x_0}{1 - \bar{\alpha}_{i-1}^2} \right) \left(\frac{\alpha_i x_i}{\beta_i^2} + \frac{\bar{\alpha}_{i-1} x_0}{1 - \bar{\alpha}_{i-1}^2} \right) \\ &= \frac{\alpha_i^2 x_i^2}{\beta_i^4} + \frac{2\bar{\alpha}_{i-1} x_0 x_i}{(1 - \bar{\alpha}_{i-1}^2)\beta_i^2} + \frac{\bar{\alpha}_{i-1}^2 x_0^2}{(1 - \bar{\alpha}_{i-1}^2)^2} \end{aligned}$$

Reverso del kernel de transición (vii)

Continuamos:

$$\begin{aligned}\frac{B^2}{A} &= \left(\frac{\alpha_i^2 x_i^2}{\beta_i^4} + \frac{2\bar{\alpha}_i x_0 x_i}{(1 - \bar{\alpha}_{i-1}^2)\beta_i^2} + \frac{\bar{\alpha}_{i-1}^2 x_0^2}{(1 - \bar{\alpha}_{i-1}^2)^2} \right) \left(\frac{1 - \bar{\alpha}_{i-1}^2}{1 - \bar{\alpha}_i^2} \beta_i^2 \right) \\ &= \frac{(\alpha_i^2 x_i^2)(1 - \bar{\alpha}_{i-1}^2)}{\beta_i^2(1 - \bar{\alpha}_i^2)} + \frac{2\bar{\alpha}_i x_0 x_i}{1 - \bar{\alpha}_i^2} + \frac{\bar{\alpha}_{i-1}^2 x_0^2 \beta_i^2}{(1 - \bar{\alpha}_{i-1}^2)(1 - \bar{\alpha}_i^2)}\end{aligned}$$

Así:

$$\begin{aligned}C - \frac{B^2}{A} &= \frac{x_i^2}{\beta_i^2} + \frac{\bar{\alpha}_{i-1}^2 x_0^2}{1 - \bar{\alpha}_{i-1}^2} - \frac{(\alpha_i^2 x_i^2)(1 - \bar{\alpha}_{i-1}^2)}{\beta_i^2(1 - \bar{\alpha}_i^2)} - \frac{2\bar{\alpha}_i x_0 x_i}{1 - \bar{\alpha}_i^2} - \frac{\bar{\alpha}_{i-1}^2 x_0^2 \beta_i^2}{(1 - \bar{\alpha}_{i-1}^2)(1 - \bar{\alpha}_i^2)} \\ &= \frac{1}{1 - \bar{\alpha}_i^2} \left(x_i^2 \left(\frac{1 - \bar{\alpha}_i^2}{\beta_i^2} - \frac{\alpha_i^2(1 - \bar{\alpha}_{i-1}^2)}{\beta_i^2} \right) - 2\bar{\alpha}_i x_0 x_i + \frac{\bar{\alpha}_{i-1}^2 x_0^2}{1 - \bar{\alpha}_{i-1}^2} (1 - \bar{\alpha}_i^2 - \beta_i^2) \right)\end{aligned}$$

Reverso del kernel de transición (viii)

$$\begin{aligned} C - \frac{B^2}{A} &= \frac{1}{1 - \bar{\alpha}_i^2} \left(x_i^2 \left(\frac{1 - \bar{\alpha}_i^2 - \alpha_i^2 + \bar{\alpha}_i^2}{\beta_i^2} \right) - 2\bar{\alpha}_i x_0 x_i + \frac{\bar{\alpha}_{i-1}^2 x_0^2}{1 - \bar{\alpha}_{i-1}^2} \alpha_i^2 (1 - \bar{\alpha}_{i-1}^2) \right) \\ &= \frac{1}{1 - \bar{\alpha}_i^2} (x_i^2 - 2\bar{\alpha}_i x_0 x_i + \bar{\alpha}_i^2 x_0^2) \\ &= \frac{(x_i - \bar{\alpha}_i x_0)^2}{1 - \bar{\alpha}_i^2} \end{aligned}$$

Que curiosamente es **igual** que el término sobrante de la suma en los términos de la exponencial, donde:

$$\begin{aligned} Ax_{i-1}^2 - 2Bx_{i-1} + C - \frac{(x_i - \bar{\alpha}_i x_0)^2}{1 - \bar{\alpha}_i^2} &= A \left(x_{i-1} - \frac{B}{A} \right)^2 + \underbrace{C - \frac{B^2}{A} - \frac{(x_i - \bar{\alpha}_i x_0)^2}{1 - \bar{\alpha}_i^2}}_0 \\ &= A \left(x_{i-1} - \frac{B}{A} \right)^2 \end{aligned}$$

Reverso del kernel de transición (ix)

Que era casualmente nuestra forma gaussiana deseada con la condición que:

$$\sigma^2 = \frac{1}{A}, \quad \mu = \frac{B}{A}$$

Lo primero ya lo verificamos, falta evaluar μ

$$\begin{aligned} \mu = \frac{B}{A} &= \left(\frac{\alpha_i x_i}{\beta_i^2} + \frac{\bar{\alpha}_{i-1} x_0}{1 - \bar{\alpha}_{i-1}^2} \right) \left(\frac{1 - \bar{\alpha}_{i-1}^2}{1 - \bar{\alpha}_i^2} \beta_i^2 \right) \\ &= \frac{\bar{\alpha}_{i-1} \beta_i^2}{1 - \bar{\alpha}_i^2} x_0 + \frac{(1 - \bar{\alpha}_{i-1}^2) \alpha_i}{1 - \bar{\alpha}_i^2} x_i \end{aligned}$$

Obteniéndose finalmente lo declarado en el lema ■

Modelamiento del objetivo generador

Habiendo demostrado todo lo anterior, sabemos que DDPM asumirá lo siguiente:

$$p_\phi(x_{i-1}|x_i) := \mathcal{N}(\mu_\phi(x_i, i), \sigma^2(i)I)$$

donde $\mu_\phi(\cdot, i) : \mathbb{R}^D \rightarrow \mathbb{R}^D$ es una estimación entrenable para la media y $\sigma^2(i) > 0$ es un valor fijo.

Recordemos el objetivo de todo modelo generativo, esta vez aplicado a DDPM.

$$\begin{aligned} \min \mathcal{D}_{\text{KL}}(p_{\text{data}}(x_0) \parallel p_\phi) &\iff \max \mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} [\log p_\phi(x_0)] \\ &\approx \\ \max \mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} [\mathcal{L}_{\text{ELBO}}(x_0; \phi)] &\iff \min \mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} [\mathcal{L}_{\text{NELBO}}(x_0; \phi)] \end{aligned}$$

Modelamiento del objetivo generador (ii)

Dentro de los términos de $\mathcal{L}_{\text{NELBO}}$ notamos que de los 3 términos encontrados $\mathcal{L}_{\text{prior}}$ es independiente de la parametrización ϕ por lo que es **despreciable**. Concentrándonos en las pérdidas $\mathcal{L}_{\text{recons.}}$ y $\mathcal{L}_{\text{diffusion}}$, el primero tiene la forma:

$$\mathcal{L}_{\text{recons.}}(x_0; \phi) = \mathcal{H}(p(x_1|x_0), p_\phi(x_0|x_1)) = \mathbb{E}_{x_1 \sim p(x_1|x_0)} [-\log p_\phi(x_0|x_1)]$$

Que puede ser calculado mediante un simple **método de Monte Carlo** o asumido por la segunda expresión; no obstante, necesitamos desplegarla para un mayor análisis.

$$\begin{aligned} \mathcal{L}_{\text{diffusion}}(x_0; \phi) &= \sum_{i=2}^L \mathbb{E}_{x_i \sim p(x_i|x_0)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i))] \\ \therefore \min \sum_{i=2}^L \mathbb{E}_{x_i \sim p(x_i|x_0)} [\mathcal{D}_{\text{KL}}(p(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i))] \\ \iff \min \sum_{i=2}^L \mathbb{E}_{x_i \sim p(x_i|x_0)} [-\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} [\log p_\phi(x_{i-1}|x_i)]] \end{aligned}$$

Modelamiento del objetivo generador (iii)

Reemplazamos con nuestra distribución modelada:

$$\begin{aligned}\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log \frac{1}{\sqrt{2\pi}\sigma(i)} e^{-\frac{\|x_{i-1} - \mu_\phi(x_i, i)\|^2}{2\sigma(i)^2}} \right] &= \mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[\log e^{-\frac{\|x_{i-1} - \mu_\phi(x_i, i)\|^2}{2\sigma(i)^2}} + \log \frac{1}{\sqrt{2\pi}\sigma(i)} \right] \\ &= \mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[-\frac{1}{2\sigma(i)^2} \|x_{i-1} - \mu_\phi(x_i, i)\|^2 \right] + C\end{aligned}$$

Para eliminar toda dependencia con x_{i-1} realicemos la siguiente simplificación considerando que $p(x_{i-1}|x_i, x_0)$ es gaussiana:

$$\begin{aligned}&\| (x_{i-1} - \mu(x_i, x_0, i)) + (\mu(x_i, x_0, i) - \mu_\phi(x_i, i)) \|^2 \\ &= \|x_{i-1} - \mu(x_i, x_0, i)\|^2 + 2\langle (x_{i-1} - \mu(x_i, x_0, i))(\mu(x_i, x_0, i) - \mu_\phi(x_i, i)) \rangle + \|\mu(x_i, x_0, i) - \mu_\phi(x_i, i)\|^2\end{aligned}$$

Modelamiento del objetivo generador (iv)

Como $\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)}[x_{i-1} - \mu(x_i, x_0, i)] = 0$, entonces el término del medio se cancela y nos queda:

$$\begin{aligned} &= \mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[-\frac{1}{2\sigma(i)^2} \left(\|x_{i-1} - \mu(x_i, x_0, i)\|^2 + \|\mu(x_i, x_0, i) - \mu_\phi(x_i, i)\|^2 \right) \right] + C \\ &= \mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[-\frac{1}{2\sigma(i)^2} \|\mu(x_i, x_0, i) - \mu_\phi(x_i, i)\|^2 \right] + \underbrace{\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} \left[-\frac{1}{2\sigma(i)^2} \|x_{i-1} - \mu(x_i, x_0, i)\|^2 \right]}_D + C \end{aligned}$$

$$\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} [\log p_\phi(x_{i-1}|x_i)] = -\frac{1}{2\sigma(i)^2} \|\mu(x_i, x_0, i) - \mu_\phi(x_i, i)\|^2 + D + C$$

Modelamiento del objetivo generador (v)

Finalmente para nuestra optimización, entonces consideraremos la siguiente función de pérdida que abarque todas las capas presentes para los pasos i :

$$\begin{aligned} \min \sum_{i=2}^L \mathbb{E}_{x_i \sim p(x_i|x_0)} \left[-\mathbb{E}_{x_{i-1} \sim p(x_{i-1}|x_i, x_0)} [\log p_\phi(x_{i-1}|x_i)] \right] \\ \iff \\ \min \sum_{i=2}^L \frac{1}{2\sigma^2(i)} \mathbb{E}_{x_i \sim p(x_i|x_0)} \left[\|\mu(x_i, x_0, i) - \mu_\phi(x_i, i)\|^2 \right] \quad \blacksquare \end{aligned}$$

Formas prácticas de modelación

Después de todo lo desarrollado uno pensaría en computar lo obtenido, pero podemos darnos cuenta que trabajar con medias puede ser demasiado costoso así como inestable en la práctica. Por esta razón se buscó una equivalencia a la hora de entrenar al decodificador.

Comenzaremos recordando que:

$$x_i = \bar{\alpha}_i x_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon \quad \epsilon \sim \mathcal{N}(0, I)$$

Ahora despejamos nuestro valor x_0 :

$$x_0 = \frac{x_i - \sqrt{1 - \bar{\alpha}_i^2} \epsilon}{\bar{\alpha}_i}$$

Formas prácticas de modelación (ii)

Si insertamos esta expresión dentro de nuestra media obtenida para $p(x_{i-1}|x_i, x_0)$ obtenemos:

$$\begin{aligned}\mu(x_i, x_0, i) &= \frac{\bar{\alpha}_{i-1}\beta_i^2}{1 - \bar{\alpha}_i^2} \left(\frac{x_i - \sqrt{1 - \bar{\alpha}_i^2}\epsilon}{\bar{\alpha}_i} \right) + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2} x_i \\&= x_i \left(\frac{\bar{\alpha}_{i-1}\beta_i^2}{(1 - \bar{\alpha}_i^2)(\bar{\alpha}_i)} + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2} \right) - \frac{\bar{\alpha}_{i-1}\beta_i^2}{(1 - \bar{\alpha}_i^2)(\bar{\alpha}_i)} \left(\sqrt{1 - \bar{\alpha}_i^2} \right) \epsilon \\&= x_i \left(\frac{\beta_i^2}{(1 - \bar{\alpha}_i^2)(\alpha_i)} + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i^2}{(1 - \bar{\alpha}_i^2)(\alpha_i)} \right) - \frac{\beta_i^2}{(1 - \bar{\alpha}_i^2)(\alpha_i)} \left(\sqrt{1 - \bar{\alpha}_i^2} \right) \epsilon \\&= x_i \left(\frac{\beta_i^2 + \alpha_i^2 - \bar{\alpha}_i^2}{(1 - \bar{\alpha}_i^2)(\alpha_i)} \right) - \frac{\beta_i^2}{\alpha_i \sqrt{1 - \bar{\alpha}_i^2}} \epsilon \\&= \frac{1}{\alpha_i} \left(x_i - \frac{\beta_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon \right) = \frac{1}{\alpha_i} \left(x_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon \right)\end{aligned}$$

Formas prácticas de modelación (iii)

Esto motiva una **nueva** parametrización que ya no dependa de x , sino:

$$\mu_{\phi}(x_i, i) = \frac{1}{\alpha_i} \left(x_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon_{\phi}(x_i, i) \right)$$

Si lo reemplazásemos en nuestra diferencia de cuadrados originales entonces tendríamos el siguiente resultado:

$$\begin{aligned} \|\mu(x_i, x_0, i) - \mu_{\phi}(x_i, i)\|^2 &= \left\| \frac{1}{\alpha_i} \left(x_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon \right) - \frac{1}{\alpha_i} \left(x_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon_{\phi}(x_i, i) \right) \right\|^2 \\ &= \left\| \frac{1}{\alpha_i} \left(\frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \right) \right\|^2 \|\epsilon - \epsilon_{\phi}(x_i, i)\|^2 \\ &= \frac{(1 - \alpha_i^2)^2}{\alpha_i^2 (1 - \bar{\alpha}_i^2)} \|\epsilon - \epsilon_{\phi}(x_i, i)\|^2 \end{aligned}$$

Formas prácticas de modelación (iv)

Ahora al incluirlo con el factor $2\sigma^2(i)$, vemos que:

$$\begin{aligned}\frac{1}{2\sigma^2(i)} \|\mu(x_i, x_0, i) - \mu_\phi(x_i, i)\|^2 &= \frac{1 - \bar{\alpha}_i^2}{2\beta_i^2(1 - \bar{\alpha}_{i-1}^2)} \frac{(1 - \alpha_i^2)^2}{\alpha_i^2(1 - \bar{\alpha}_i^2)} \|\epsilon - \epsilon_\phi(x_i, i)\|^2 \\ &= \frac{\beta_i^4}{2\beta_i^2\alpha_i^2(1 - \bar{\alpha}_{i-1}^2)} \|\epsilon - \epsilon_\phi(x_i, i)\|^2 \\ &= \frac{\beta_i^2}{2\alpha_i^2(1 - \bar{\alpha}_{i-1}^2)} \|\epsilon - \epsilon_\phi(x_i, i)\|^2 \\ &= \frac{1 - \alpha_i^2}{2\alpha_i^2(1 - \bar{\alpha}_{i-1}^2)} \|\epsilon - \epsilon_\phi(x_i, i)\|^2 \\ &\propto \|\epsilon - \epsilon_\phi(x_i, i)\|^2 \quad \blacksquare\end{aligned}$$

Formas prácticas de modelación (v)

Notaremos directamente que la expresión muestra que, para cada paso i , la pérdida es proporcional a $\|\epsilon - \epsilon_\phi\|^2$ con un coeficiente positivo que depende únicamente del paso.

Dado que nuestro factor $\frac{1-\alpha_i^2}{2\alpha_i^2(1-\bar{\alpha}_{i-1}^2)} > 0$ es constante para cada i , minimizar dicha suma será equivalente a minimizar la suma de los términos **NO** ponderados.

Esto justifica la adopción de una pérdida simplificada que trata todos los pasos de manera uniforme:

$$\mathcal{L}_{\text{simple}}(\phi) = \mathbb{E}_{i \sim \mathcal{U}\{1, \dots, L\}} \mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I)} \left[\|\epsilon_\phi(x_i, i) - \epsilon\|^2 \right]$$

$$\text{donde } x_i = \bar{\alpha}_i x_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon, \quad x_0 \sim p_{\text{data}}$$

No solo simplifica el cómputo, sino que gracias a la distribución de $\epsilon \sim \mathcal{N}(0, I)$ permite una estabilidad en sus gradientes que se ve perjudicado al añadir la ponderación dada para cada paso i que altera su varianza.

Muestreo de nuevos datos

Una vez entrenado el modelo de predicción de ϵ dado como $\epsilon_{\phi^\times}(x_i, i)$, realizamos un muestreo secuencial usando la transición parametrizada $p_{\phi^\times}(x_{i-1}|x_i)$.

En particular, comenzaremos con una semilla aleatoria $x_L \sim p_{\text{prior}} = \mathcal{N}(0, I)$ y obtenemos un muestreo recursivo de $p_{\phi^\times}(x_{i-1}|x_i)$ siguiendo la regla de actualización:

$$x_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i} \left(x_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon_{\phi^\times}(x_i, i) \right)}_{\mu_{\phi^\times}(x_i, i)} + \sigma(i) \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, I)$$

La limpieza del ruido sucede hasta llegar al x_0 donde obtenemos una muestra generada limpia.

Problemas con DDPM

Nuevamente, aunque todo se vea **bonito**, su muestreo es inherentemente lento debido a la naturaleza secuencial de su proceso de reversión que esta restringido por factores condicionales.

Nuestros teoremas indican que un modelo expresivo $p_\phi(x_{i-1}|x_i)$ puede teóricamente ser idéntica a $p(x_{i-1}|x_i)$; sin embargo, al ser modelado típicamente como una distribución gaussiana puede limitar su expresividad.

Además, el modelo es sensible a los hiperparámetros $\{\beta_i\}_{i=1}^L$, ya que valores largos β_i pueden inducir una fuerte distribución no gaussiana, por lo que para mantener precisión y estabilidad se emplean varios valores pequeños β_i .

Existen modelos y algoritmos capaces de solventar estos problemas, pero ojala que con estas bases a modelos un poco más **simples** puedan abrirse paso para un mejor entendimiento de los mismos.

4. Referencias

Referencias

- [1] C.-H. Lai, Y. Song, D. Kim, Y. Mitsufuji, y S. Ermon, «The Principles of Diffusion Models: From Origins to Advances». [En línea]. Disponible en: <https://arxiv.org/abs/2510.21890>
- [2] I. Goodfellow, Y. Bengio, y A. Courville, *Deep Learning*. MIT Press, 2016. [En línea]. Disponible en: <https://www.deeplearningbook.org/>
- [3] J. F. Silva, V. Faraggi, C. Ramirez, A. Egaña, y E. Pavez, «Understanding Encoder-Decoder Structures in Machine Learning Using Information Measures». [En línea]. Disponible en: <https://arxiv.org/abs/2405.20452>